

Разработка и экспериментальное исследование консольного архиватора на основе алгоритма Хаффмана

Емельяничков Даниил

Группа: 25Б.71-мм

Кафедра: системного программирования, СПбГУ

Научный руководитель: Литвинов Юрий Викторович

Консультант: не назначен

Номер семестра практики: 2

1. Постановка задачи

Работа выполнена в рамках учебной практики по заданию преподавателя. Цель — разработать консольное приложение для сжатия и восстановления произвольных файлов без потери данных, а также экспериментально оценить степень сжатия и время работы на данных разных типов и размеров. Результат предназначен для демонстрации алгоритма Хаффмана и его ограничений на несжимаемых и уже сжатых данных.

2. Описание решения


Приложение реализовано на C++17 с использованием CMake. При сжатии программа подсчитывает частоты байтов, строит дерево Хаффмана с помощью очереди с приоритетами и записывает в архив сигнатуру, исходный размер, таблицу частот и битовый поток. Построение дерева занимает $O(k \log k)$ для k различных байтов. При распаковке частоты проверяются на согласованность с исходным размером; битовый ввод буферизован блоками по 64 КиБ. Формат поддерживает любые байты, включая нулевые.

3. Апробация и эксперименты


Корректность проверена 23 тестами CTest: модульными тестами дерева, битового ввода-вывода и кодека, а также CLI-интеграционными тестом. Дополнительно выполнены round-trip-проверки на 19 наборах; во всех случаях SHA-256 восстановленного файла совпал с исходным. Тесты проверяют пустой файл, полный байтовый алфавит, границу буфера, повреждённые архивы и несогласованную таблицу частот.

Эксперимент включал текст, исходный код, случайные данные и ZIP-архивы разных размеров. Для каждого набора выполнен один прогревочный и 30 измеряемых запусков. В таблице приведены среднее и выборочное стандартное отклонение времени; степень сжатия — отношение размера архива к размеру входа. Замеры выполнены в Release-сборке на Windows 11 x64; таймер включает запуск процесса и файловый ввод-вывод.


Набор (размер входа)	Архив/вход, %	Сжатие, мс	Распаковка, мс
Текст (1 КиБ)	154,9	22,87 ± 0,67	23,00 ± 0,83
Текст (100 КиБ)	65,6	25,06 ± 0,67	25,34 ± 0,69
Текст (1 МиБ)	63,1	39,54 ± 1,23	45,68 ± 1,34
Полный текст (3,12 МБ)	62,2	68,95 ± 1,22	87,62 ± 1,16
Исходный код (10,9 КиБ)	65,9	23,19 ± 0,64	23,59 ± 0,79
Случайные данные (1 МиБ)	100,2	40,14 ± 0,79	40,27 ± 0,77
ZIP полного текста (1,26 МБ)	100,2	43,41 ± 0,76	43,88 ± 0,95



Размер архива относительно входа



Время сжатия



Время распаковки

Для текстовых данных размер архива составил 62–66% от исходного на файлах от 100 КиБ. На случайных данных размер архива близок к исходному для крупных файлов, но для файла 1 КиБ он достигает 321,5% из-за заголовка и таблицы частот. Для ZIP-файлов превышение на крупных наборах составляет около 0,2%. Результаты показывают, что эффективность зависит от структуры и размера входа.

4. Заключение

Разработан и проверен консольный архиватор без потерь с форматом HUF1. Реализованы построение кодов Хаффмана, упаковка битового потока, восстановление файлов и проверка целостности заголовка. Подготовлены модульные и CLI-интеграционные тесты, воспроизводимый сценарий эксперимента, CSV-таблицы и графики. Материалы эксперимента находятся в каталоге `experiments/` репозитория.

Репозиторий: https://github.com/dem0phob1a/huffman_archiver_dem0phob1a.

Техническая документация: файл `README.md` в репозитории.

Статус: реализация и экспериментальные материалы подготовлены к передаче преподавателю для получения отзыва; промышленное внедрение не заявляется.